

张天舒

手机：(+86) 18501985856 · 微信：zhangts22
邮箱：zhangts22@mails.tsinghua.edu.cn



教育背景

清华大学，软件工程，本科
清华大学，软件工程，硕士

2022.09 - 2026.7
2026.09 (拟入学) - 2028.7

实习经历

智谱华章科技有限公司，算法实习生

2025.5-现在

- 参与 GLM-4.1V-thinking、GLM-4.5V/4.6V、GLM-5V-turbo 等多模态模型的训练工作，负责视频定位、理解和推理任务的 SFT/RL 数据构建、质量验证、难例筛选和 RL 阶段 verifier 调优。
- 参与视频剪辑方向优化，覆盖长视频剪辑、片段精选、字幕添加等任务，通过设计并优化 harness、构造高质量训练和评测数据，提升模型在剪切点选择、片段衔接自然度和基础后处理上的表现。
- 参与 grounding 专用模型研发，主要负责视频时空定位任务的数据建设与验证，使模型在同类任务上取得领先效果。

THUBPM 实验室，科研实习生

2024.3-现在

- 进行可信多模态大模型方向的研究，产出多篇高水平论文

科研经历

ICT: Image-Object Cross-Level Trusted Intervention for Mitigating Object Hallucination in Large Vision-Language Models

Junzhe Chen*, Tianshu Zhang*, Shiyu Huang, Yuwei Niu, Linfeng Zhang, Lijie Wen, Xuming Hu
Conference on Computer Vision and Pattern Recognition (CVPR) 2025

这项工作中，我们提出了一种无需训练，即插即用的缓解 LVLMs 物体幻觉的方法。我们通过在向前传播阶段施加预先计算的干预，在整体和细粒度两个层次上增强了模型对视觉部分的关注度，从而减轻了有害的语言先验。

OmniDPO: A Preference Optimization Framework to Address Omni-Modal Hallucination

Junzhe Chen*, Tianshu Zhang*, Shiyu Huang, Yuwei Niu, Chao Sun, Rongzhou Zhang, Guanyu Zhou, Lijie Wen, Xuming Hu
Annual AAAI Conference on Artificial Intelligence (AAAI) 2026

我们提出了一种缓解全模态大模型幻觉的 DPO 框架以及对应的偏好数据集。这一方法有效解决全模态大模型的模态不平衡和音视频缺陷问题的同时，还带来了多模态推理能力的提升。

VisWordBench: Bridging the Gap in Cross-modal Reasoning for Multimodal Large Language Models

Tianshu Zhang*, Junzhe Chen*, Yean Cheng, Demin Zhu, Haoze Zheng, Lijie Wen, Xuming Hu
European Conference on Computer Vision (ECCV) 2026

这项工作中，我们提出了一个包含 4,625 道中英文视觉字谜的跨模态推理评测基准，综合考察模型的视觉感知、世界知识与跨模态推理能力。通过对模型推理过程的结构化分析，我们发现其核心瓶颈在于候选假设探索不足，并进一步提出数据合成与无需训练的推理引导方法，有效提升了多模态大模型的跨模态推理能力。

Efficient Spatio-Temporal Grounding with Multimodal Large Models via Second-Level Tracking and RL Verification

Tianshu Zhang, Yan Wang, Ji Qi, Lijie Wen

我们提出了一种面向长视频时空定位的多模态大模型框架。该方法通过逐秒追踪与跨秒平滑降低长视频处理开销并保持轨迹连续性，同时结合推理监督和强化学习，提升模型对目标事件的时间定位与物体追踪能力，使 9B 模型达到了 SOTA 水平。

技术报告

GLM-4.5 V and GLM-4.1 V-Thinking: Towards Versatile Multimodal Reasoning with Scalable Reinforcement Learning

系统介绍 9B 参数模型与 106B 总参数、12B 激活参数 MoE 视觉语言模型的训练方法，在多数多模态理解与推理 benchmark 上达到 SOTA 水平。

GLM-5V-Turbo: Toward a Native Foundation Model for Multimodal Agents

介绍面向多模态 Agent 场景的原生视觉语言基础模型，覆盖图像、视频与工具使用等复杂任务，并在主流 benchmark 上取得领先效果。

所获荣誉

- 国家奖学金
- 清华大学优良毕业生
- 清华大学软件学院优秀毕业生
- 综合优秀奖学金
- 学业优秀奖学金
- 软件创新创业大赛二等奖
- CET6 (619)